IMPLEMENTAR UNA HERRAMIENTA DE SISTEMAS DE INTELIGENCIA ARTIFICIAL PARA ESTIMAR TARIFAS EN EL SECTOR DE HOTELES

MÁSTER EN DATA SCIENCES & BUSINESS ANALYTICS

TRABAJO FIN DE MÁSTER

Cristina Duzhang

AGENDA DE LA PRESENTACIÓN

01 Contexto y Problemática del Sector Hotelero

02 Objetivos del Proyecto

03 Descripción del Dataset

04 Arquitectura del Modelo Predictivo

05 Ingeniería de Características

06 Modelos de Machine Learning Evaluados

07 Métricas de Evaluación y Resultados

08 Dashboard e Interfaz de Usuario

09 Impacto de Negocio y ROI

10 Conclusiones y Próximos Pasos

CONTEXTO Y PROBLEMÁTICA

Volatilidad

El sector enfrenta una alta volatilidad en precios por estacionalidad y competencia dinámica.

Pérdidas

Precios fijos tradicionales causan subvaloración o baja ocupación por sobrevaloración.

Limitación

La falta de herramientas predictivas limita la respuesta al mercado en tiempo real.

NUESTRA PROPUESTA: MACHINE LEARNING

Un sistema inteligente que integra múltiples variables para estimar el precio diario óptimo, maximizando ingresos y ocupación mediante modelos predictivos avanzados.

OBJETIVOS DEL PROYECTO

Objetivo General

Desarrollar un modelo predictivo de Data Science que estime el precio óptimo diario de habitaciones hoteleras, integrando variables de mercado, demanda y características del establecimiento.

Objetivos Específicos

- Recolectar y limpiar datos históricos de precios, ocupación y variables externas.
- Identificar los factores más influyentes en la determinación del precio.
- Entrenar y comparar múltiples algoritmos de regresión.
- Desplegar una API REST para consultas en tiempo real.
- Crear un dashboard interactivo para el equipo comercial.

DESCRIPCIÓN DEL DATASET

Fuente de Datos

Registros históricos de 5 años de una cadena hotelera regional.

- 150+ propiedades
- 500K+ registros

Variables Principales

Atributos base del establecimiento y su desempeño.

- Precio por noche y ocupación
- Categoría y ubicación
- Amenities y reseñas

Variables Temporales

Factores de tiempo que afectan la demanda.

- Día, mes y temporada
- Festivos y ferias
- Eventos locales

Variables de Mercado

Entorno competitivo y demanda regional.

- Precios de competidores
- Disponibilidad en OTAs
- Índice de demanda

Variables Externas

Indicadores macro y ambientales.

- Clima y tráfico aéreo
- Índice económico local
- Tendencias Google

Preprocesamiento

Tratamiento técnico de la data.

- Imputación y encoding
- Normalización
- Detección de outliers

Arquitectura del Sistema

Ingeniería de Características

CARACTERÍSTICAS CREADAS

- **Lag features:** precios y ocupación de los últimos 7, 14 y 30 días.
- **Rolling averages:** media móvil de precios de competidores.
- **Ratios:** precio_vs_competencia, ocupación_vs_capacidad.
- **Codificación temporal:** sin/cos para día del año y día de la semana.
- **Clusters geográficos:** agrupación de hoteles por zona de demanda.

TRANSFORMACIONES APLICADAS

- **One-hot encoding** para categorías de hotel: (boutique, resort, business).
- **Target encoding** para variables de alta cardinalidad: ciudad, barrio).
- **Log-transform** precios para reducir asimetría.
- **Escalado con RobustScaler** para variables numéricas con outliers.
- **Feature selection:** SHAP values y Recursive, RFE.

Métricas de Evaluación

INTERPRETACIÓN DEL ERROR

MAE

MAE (Error Absoluto Medio): interpretable en unidades monetarias.

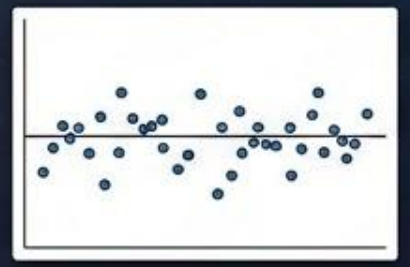

RMSE

RMSE (Error Cuadrático Medio): penaliza errores grandes en precios.

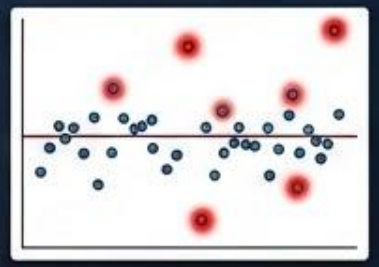

CONTEXTO DEL MODELO

MAPE

MAPE (Error Porcentual Absoluto Medio): precisión relativa.

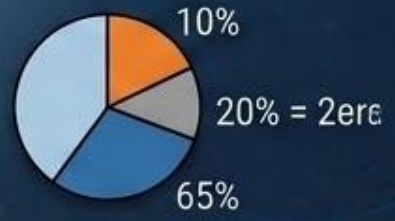

$$\text{Error} = \frac{\text{Error} - \text{MAE}}{\text{MAPE}} \times 1.5$$

MASE

(Error Escalado Absoluto Medio): contra naive forecast.

R^2 Score: proporción de varianza explicada por el modelo.

Métricas de Evaluación y Validación

R^2 Score
Proporción de varianza explicada.

MASE Escalado Absoluto Medio
Comparación contra naive forecast.

MAPE Error Porcentual Absoluto Medio
Comparación de precisión relativa.

RMSE Error Cuadrático Medio
Penaliza errores grandes en precios.

MAE Error Absoluto Medio
Interpretable en unidades monetarias.

Time Series Split
Respeta orden temporal in los folds.

Walk-forward Validation
Simula despliegue en producción.

Estratificación por Temporada
Asegurar representatividad estacional.

Monitoreo de Drift en Features
Entre entrenamiento y test.

A/B Testing (10%)
Antes de rollout completo.

Dashboard e Interfaz de Usuario

Panel de Control Principal

Visualización de precios recomendados vs precios actuales por hotel y fecha.

Calendario de Precios

Heatmap interactivo que muestra precios óptimos día a día con alertas de subvaloración.

Análisis de Competencia

Comparación de precios propios vs competidores en tiempo real.

Simulador What-If

Permite ajustar variables y ver el impacto en el precio recomendado.

Alertas Automáticas

Notificaciones cuando el precio actual difiere >15% del precio óptimo estimado.

Acceso multirol

Vistas diferenciadas para revenue managers, directores de hotel y analistas.

Impacto de Negocio y ROI

Beneficios Cuantitativos

- Incremento del 12% en RevPAR (Revenue per Available Room) en el primer trimestre.
- Reducción del 18% en habitaciones subvaloradas durante alta demanda.
- Ahorro de 120 horas/mes del equipo de revenue management en análisis manual.
- Mejora del 8% en ocupación al ajustar precios en temporada baja.

Beneficios Cualitativos

- Decisiones de precios basadas en datos, no en intuición.
- Mayor agilidad ante cambios de mercado (respuesta en minutos, no días).
- Estandarización del proceso de fijación de precios entre hoteles.
- Base sólida para futuras expansiones del modelo a otros mercados.

+12% RevPAR

120 H/Mes

Datos

Agilidad

-18% Habitaciones

+8% Ocupación

Estándar

Expansión

Retos y Mitigaciones

CALIDAD DE DATOS DE COMPETIDORES

scraping de OTAs con rotación de proxies y validación cruzada de fuentes.

OVERFITTING EN HOTELES BOUTIQUE

$$\text{reg.} = \sum_{i=1}^{n} (l + r)^2$$

regularización L1/L2 y validación estricta con datos no vistos.

DRIFT DEL MODELO

pipeline de reentrenamiento automático mensual con monitoreo de degradación de métricas.

ESTACIONALIDAD EXTREMA

uso de Fourier features y modelos específicos por temporada para capturar picos.

RESISTENCIA AL CAMBIO

programa de capacitación y dashboards intuitivos para facilitar adopción.

ESCALABILIDAD

arquitectura serverless en AWS para manejar picos de demanda sin interrupciones.

Conclusiones

1 Machine Learning y Valor

Demuestra que el Machine Learning puede generar valor tangible en revenue management.

2 Integración de Datos

Permite capturar la complejidad del mercado hotelero de forma robusta.

3 Enfoque Ensemble

Ofrece el mejor balance entre precisión, interpretabilidad y velocidad de inferencia.

4 Sostenibilidad y Automatización

Pipeline Automatizado Garantiza Sostenibilidad Largo Plazo.

5 Impacto de Negocio

Mejora Decisiones Comerciales e Ingresos Operativos.

6 Expansión a Otros Segmentos

Bases para Expandir: Renta Autos, Cruceros, Vuelos.

FIN

Gracias por su atención